

2026-1학기 빅데이터프로그래밍

프로젝트 수행계획서

제출일자 : 2026. 03. 30

작성자 : 레옹

팀 명	레옹			
분반	빅데이터프로그래밍[A]			
팀 원	이름	학번	연락처	E-mail
	정래원	2071117	010-2205-6501	fodnjs15@hansung.ac.kr
	김동현	2371096	010-6290-1528	0424dhdh@hansung.ac.kr
	김홍근	2191049	010-9859-3459	2191049@hansung.ac.kr
	이승준	1971090	010-2207-8648	netisky2@hansung.ac.kr
	이윤수	2171120	010-8277-4058	mooksu2@hansung.ac.kr

목 차

1. 프로젝트 개요	1
1.1 프로젝트 수행 배경 및 필요성	1
1.2 프로젝트 목표	1
1.3 연구 문제 및 가설 설정	1
2. 관련 연구 및 기술 배경	2
2.1 기존 연구 및 기술 동향 조사	2
2.2 기존 접근 방식의 한계 분석	2
2.3 본 프로젝트 접근 방식의 차별성	2
3. 실험 데이터	3
3.1 데이터 확보 방안	3
3.2 데이터 전처리 방법	3
3.3 데이터 활용 계획	3
4. 모델 설계	4
4.1 적용 예정 모델	4
4.2 모델 선정 이유	4
4.3 학습 방법 및 학습 전략	4
4.4 하이퍼파라미터 튜닝 계획	4
5. 실험 및 평가 방법	5
5.1 베이스라인 모델 설정	5
5.2 실험 설계 방법	5
5.3 모델 성능 평가 지표	5
5.4 모델 비교 및 분석 계획	5

6. 프로젝트 일정 및 역할 분배	6
6.1 전체 프로젝트 일정 계획	6
6.2 주요 마일스톤 설정	6
6.3 팀원별 역할 분담	6
7. 기대 효과 및 한계점	7
7.1 기대 성과 및 활용 가능성	7
7.2 예상되는 어려움 및 해결 계획	7
7.3 프로젝트의 잠재적 한계	7
8. 참고문헌	8

법률 판례 텍스트 기반 사건 대분류 분류 모델 성능 비교

1. 프로젝트 개요

1.1 프로젝트 수행 배경 및 필요성

최근 법률 분야에서도 인공지능 기술을 활용한 자동화 연구가 활발하게 이루어지고 있다. 특히 판례와 같은 법률 문서는 길고 복잡한 구조를 가지고 있어, 사건의 핵심 내용을 파악하고 유형을 분류하는 데 많은 시간과 전문적인 지식이 필요하다. 하지만 실제로는 방대한 양의 판례가 지속적으로 축적되고 있으며, 이를 사람이 일일이 분석하는 데에는 한계가 있다. 따라서 이러한 문제를 해결하기 위해, 판례 텍스트를 기반으로 사건 유형을 자동으로 분류하는 시스템의 필요성이 증가하고 있다. 또한 최근 자연어 처리 기술의 발전으로 텍스트 데이터를 효과적으로 처리할 수 있는 다양한 모델들이 등장하고 있으며, 특히 BERT와 같은 사전학습 언어모델은 기존 방법보다 뛰어난 성능을 보이고 있다. 이에 본 프로젝트에서는 법률 판례 데이터를 활용하여 사건 유형 분류 문제를 해결하고, 서로 다른 모델 간 성능 차이를 비교 분석함으로써 텍스트 분류 문제에 대한 이해를 높이고자 한다.

1.2 프로젝트 목표

본 프로젝트의 주요 목표는 판례 텍스트를 기반으로 사건의 대분류를 자동으로 예측할 수 있는 모델을 구현하는 것이다. 이를 위해 판례 데이터에 포함된 텍스트 정보를 활용하여 분류 모델을 구축하고, 서로 다른 방식의 텍스트 표현이 모델 성능에 어떤 영향을 미치는지를 비교 분석하고자 한다. 특히 TF-IDF 기반의 전통적인 머신러닝 모델과 BERT에서 추출한 임베딩을 활용한 MLP 분류 모델을 적용하여 성능 차이를 확인하고, 법률 텍스트와 같이 길고 복잡한 문장에서 문맥 정보가 얼마나 중요한 역할을 하는지도 함께 살펴볼 예정이다. 또한 단순히 모델을 구현하는 데 그치지 않고, 각 모델의 결과를 분석하여 어떤 방식이 법률 텍스트 분류에 더 적합한지 해석하는 것을 목표로 한다.

1.3 연구 문제 및 가설 설정

본 프로젝트에서는 판례 텍스트를 활용하여 사건의 대분류를 얼마나 정확하게 예측할 수 있는지를 중심으로 분석을 진행한다. 특히 동일한 데이터라 하더라도 텍스트를 어떻게 표현하느냐에 따라 모델의 성능이 달라질 수 있다는 점에 주목하였다. 이에 따라 본 연구에서는 전통적인 TF-IDF 기반 표현 방식과 문맥 정보를 반영하는 BERT 기반 표현 방식을 비교하여, 각 방법이 분류 성능에 어떤 차이를 보이는지 확인하고자 한다. 또한 판례 텍스트가 길고 복잡한 구조를 가지는 특성을 고려할 때, 단어 빈도 중심의 표현보다 문맥을 반영하는 방식이 더 효과적인지 검증하는 것을 중요한 분석 목표로 설정하였다. 이와 함께 입력으로 사용하는 텍스트의 종류에 따라서도 성능 차이가 발생할 수 있다고 판단하였다. 판시사항과 요약문은 정보의 밀도와 표현 방식이 다르기 때문에, 어떤 텍스트가 분류에 더 적합한지 비교 분석하고자 한다. 또한 두 텍스트를 결합하여 사용하는 경우 성능이 향상되는지도 함께 확인할 예정이다.

이러한 분석을 바탕으로, 본 프로젝트에서는 다음과 같은 결과를 기대한다. 문맥 정보를 활용하는 BERT 기반 모델이 TF-IDF 기반 모델보다 전반적으로 높은 분류 성능을 보일 것으로 예상하며, 요약문보다는 판시사항과 같은 원문 정보가 더 중요한 특징으로 작용할 가능성이 높다고 판단한다. 또한 단일 텍스트보다 여러 정보를 함께 사용하는 방식이 성능 향상에 기여할 것으로 기대한다.

2. 관련 연구 및 기술 배경

2.1 기존 연구 및 기술 동향 조사

법률 텍스트 분류 연구는 전통적 머신러닝 기반 접근과 사전학습 언어모델 기반 접근으로 나뉜다. Vatsal et al은 미국 대법원 판례 8,419건을 대상으로 Legal-BERT가 일반 BERT, RoBERTa, LongFormer보다 분류 성능이 높음을 확인하였다. 판례 평균 길이가 6,960 토큰으로 BERT의 512 토큰 제한을 크게 초과하지만, 4,096 토큰을 처리하는 LongFormer보다 Legal-BERT + Stride-64 조합(80.1%)이 더 높았다. 입력 길이를 늘리는 것보다 도메인 특화 사전학습이 분류 정확도에 더 기여한다는 점을 알 수 있다. Lee는 한국어 성범죄 판례 3,579건을 10개 유형으로 분류하면서, fine-tuning된 KLUE-BERT(99.30%)가 SVM(83~85%), Llama-3.1-polyglot-ko(71~79%), GPT-4.0 Few-Shot(72.61%) 모두를 상회함을 보였다. 도메인에 맞게 fine-tuning된 소형 모델이 범용 대형 모델보다 나올 수 있다는 결과다. AI Hub에서는 같은 판례 데이터셋으로 BERT를 fine-tuning한 판결예측모델은 긍정,부정 그리고 불명 3분류로 제공하나, 사건 유형 분류는 다루지 않았고 단일 모델 결과만 제시하고 있다.

2.2 기존 접근 방식의 한계 분석

앞선 연구들은 법률 텍스트 분류의 가능성을 보여주었으나 몇 가지 한계가 있다. 첫째, 분류 범위가 제한적이다. Vatsal et al은 미국 판례만, Lee는 한국어 성범죄 판례의 세부 유형 분류에 한정된다. 민사,형사,행정 등 전 법률 분야를 아우르는 대분류 연구는 아직 없다. 둘째, 입력 텍스트 선택에 대한 비교가 없다. 세 연구 모두 입력을 하나로 고정했다. 실제 판례 데이터에는 판시사항, 요약문, 전문 등 여러 필드가 있고, 어떤 필드를 쓰느냐에 따라 정보 밀도와 문맥 범위가 달라지지만 이를 비교한 실험은 없었다. 셋째, 텍스트 표현 방식 간 비교가 부족하다. Vatsal et al은 BERT 계열 내부 비교에 집중했고, Lee는 TF-IDF 기반 Logistic Regression 같은 전통적인 머신러닝 모델을 포함하지 않았고 단어 빈도 기반과 문맥 기반 표현이 동일 조건에서 얼마나 차이 나는지는 확인되지 않았다. 넷째, 한국어 법률 특화 모델 간 직접 비교가 없다. 법률 도메인 사전학습이 한국어 판례 분류에서 실제로 유효한지 검증이 필요하다. 다섯째, AI Hub 모델과 목적이 다르다. AI Hub는 판결 결과를 긍정,부정,불명으로 나누는 3가지 분류이고, 본 프로젝트가 수행하려는 10개 사건 유형 분류이다.

2.3 본 프로젝트 접근 방식의 차별성

앞선 한계를 바탕으로 본 프로젝트는 네 가지 방향에서 기존 연구와 다른 접근을 취한다. 첫째,

AI Hub 판례 데이터 66,511건을 활용하여 민사,가사,형사,행정,기업,근로자,특허/저작권,금융조세,개인정보/ICT 등 10개 카테고리로 분류한다. 단일 분야가 아닌 범용 사건 유형 분류에 해당한다. 둘째, 같은 판례에서 판시사항, 요약문, 두 텍스트의 결합 각각에 대해 분류 성능을 비교한다. 판시사항은 법률 용어가 밀집되어 있고 요약문은 짧고 핵심 위주인데, 기존 연구에서는 입력을 하나로 고정했기 때문에 이런 비교가 이루어진 적이 없다. 셋째, TF-IDF 기반 Logistic Regression과 SVM으로 baseline을 잡고, BERT 임베딩을 MLP 분류기에 넣는 구조를 직접 설계한다. 사전학습 모델을 그대로 쓰지 않으므로 단어 빈도 기반과 문맥 기반 표현의 차이를 같은 조건에서 비교할 수 있다. 넷째, TF-IDF 특징과 BERT 임베딩을 결합한 하이브리드 모델을 실험한다. 서로 다른 표현 방식을 합쳤을 때 성능이 실제로 올라가는지 확인하기 위한 것으로, 기존 법률 텍스트 분류 연구에서는 시도된 바 없다.

3. 실험 데이터

3.1 데이터 확보 방안

본 프로젝트에서 사용하는 데이터는 AI Hub에서 공개 제공하는 상황에 따른 판례 데이터로, 별도의 수집 없이 직접 다운로드하여 활용할 수 있다. 실제 법원 판례를 기반으로 구축된 약 66,511건의 데이터로 구성되며, JSON 형식으로 제공된다. 각 판례는 판시사항, 요약문 등 여러 텍스트 필드를 포함하고 있으며, 민사, 가사, 형사, 행정, 기업, 근로자, 특허/저작권, 금융조세, 개인정보/ICT 등 총 10개의 사건 대분류 라벨이 함께 제공된다. 실제 판례에 기반한 데이터인 만큼 현실적인 법률 텍스트의 특성이 그대로 반영되어 있어, 분류 모델의 실용성을 검증하기에 적합하다.

3.2 데이터 전처리 방법

수집된 데이터는 모델 학습에 앞서 다음과 같은 과정을 거쳐 전처리된다. 우선 결측치와 null 값을 확인하고, 판시사항이나 요약문 필드가 비어 있는 경우 해당 샘플은 분석에서 제외한다. 텍스트 정제 측면에서는 특수문자와 불필요한 공백을 제거한다. 법률 텍스트 특성상 판례 번호, 날짜 표기, 조항 기호 같은 표현이 빈번하게 등장하기 때문에, 이를 일관된 기준으로 처리하는 작업이 필요하다. 텍스트 길이도 사전에 파악해둬야 하는데, 판시사항은 요약문에 비해 길이가 긴 경우가 많아 BERT의 최대 입력 토큰 제한을 초과할 가능성이 있으므로, 길이 분포를 확인하고 처리 방식을 미리 결정한다. 클래스 불균형 여부도 함께 확인하여 10개 카테고리 간 샘플 수 차이가 어느 정도인지 파악해둔다.

3.3 데이터 활용 계획

전처리가 완료된 데이터는 학습, 검증, 테스트 세트로 나누어 활용한다. 입력 텍스트는 판시사항만 사용하는 경우, 요약문만 사용하는 경우, 그리고 두 텍스트를 결합하여 사용하는 경우를 총 세 가지 조건으로 구성하여 각각 실험한다. 구성된 데이터는 TF-IDF 기반 모델인 Logistic Regression과 SVM 그리고 BERT에서 추출한 임베딩을 활용해 직접 설계한 MLP 분류 모델에 동일하게 적용된다. 모델 간 성능은 정확도, Macro F1-score, 정밀도, 재현율을 기준으로 비교하며, 클래스별 성능분포도 함께 살펴본다.

4. 모델 설계

본 프로젝트는 법률 판례의 10개 대분류를 예측하기 위해, 전통적인 머신러닝 모델인 베이스라인과 BERT 임베딩 기반의 MLP 모델, 그리고 이를 결합한 하이브리드 모델을 설계하여 성능을 비교 분석한다.

4.1 적용 예정 모델

1.3의 가설 검증과 2.3에서 제시한 차별성을 확보하기 위해 세 가지 모델을 구축한다. 텍스트를 단어 빈도 중심의 TF-IDF 벡터로 변환한 뒤, Baseline으로 Logistic Regression과 SVM(LinearSVC)을 설정한다. 두 모델은 TF-IDF로 수치화된 고차원 희소 벡터에서 안정적인 성능을 보이며, 이후 모델들과의 성능 비교를 위한 기준으로 활용한다. 다음으로 BERT 임베딩 기반 모델을 구축한다. 사전 학습된 BERT 모델을 '특징 추출기(Feature Extractor)'로 활용한다. 법률 문맥이 반영된 768차원의 수치 벡터를 추출하고, 이를 입력으로 받는 다층 퍼셉트론(MLP) 분류기를 결합하여 문장의 의미적 맥락을 학습시킨다. 마지막으로 특징 융합 하이브리드 모델을 설계한다. 이 모델은 단어 빈도 기반의 TF-IDF 특징과 문맥 기반의 BERT 임베딩을 결합하여 최종 분류를 수행하며, 서로 다른 텍스트 표현 방식의 장점을 동시에 활용한다는 점에서 본 프로젝트의 핵심 차별점이다.

4.2 모델 선정 이유

위 모델 조합을 선택한 이유는 두 가지이다. 첫째, 단어 빈도 중심인 TF-IDF와 문맥 중심인 BERT라는 서로 다른 텍스트 표현 방식이 법률 텍스트 분류에 미치는 영향을 동일 조건에서 객관적으로 비교하기 위함이다. 둘째, Baseline으로 설정한 선형 모델의 가중치를 분석하면 어떤 법률 키워드가 분류에 핵심적인 역할을 했는지 해석할 수 있어, 결과의 설명 가능성을 확보할 수 있다.

4.3 학습 방법 및 학습 전략

전체 데이터는 학습, 검증, 테스트 세트로 8:1:1 비율로 분할하며, 10개 클래스의 비율을 유지하는

StratifiedSplit을 적용한다. 입력 텍스트는 판시사항, 요약문, 두 텍스트의 결합인 세 가지 조건으로 구성하여, 각 조건에 대해 모든 모델의 성능을 측정할 수 있도록 파이프라인을 설계한다. 10개 대분류 간 샘플 수 차이가 존재하기 때문에, 학습할 때에 `class_weight='balanced'` 파라미터를 적용하여 소수 범주에 대한 가중치를 높인다. 또한 StratifiedKFold를 사용하여 교차 검증 시에도 10개 클래스의 비율을 일정하게 유지한다. 입력 조건을 판시사항 단독, 요약문 단독, 그리고 두 텍스트를 합친 경우까지 총 세 가지 케이스로 나누어, 이를 각각 실험하여 어떤 데이터 조합이 분류에 가장 유리한지 찾아낸다. BERT 임베딩 기반 모델과 하이브리드 모델의 경우, BERT는 사전학습 가중치를 고정한 상태에서 임베딩 추출 용도로만 사용하며, 추출된 768차원 벡터를 입력으로 받는 MLP 분류기를 PyTorch로 구현한다. 손실 함수는 다중 클래스 분류에 적합한 CrossEntropyLoss를 사용하고, 옵티마이저는 Adam을 적용한다.

4.4 하이퍼파라미터 튜닝 계획

모델 별 최적 성능을 끌어내기 위해 GridSearchCV로 주요 변수를 조정한다.

모델 구분	주요 튜닝 항목	상세 전략
TF-IDF & SVM	ngram_range, C	단어 조합의 범위(1~2 단어)와 규제 강도 최적화
BERT + MLP	Hidden_layer_sizes, learning_rate	임베딩을 효과적으로 분류할 은닉층 깊이와 학습률 조정
Hybrid (Fusion)	fusion_weights, dropout	두 특징 간의 결합 가중치 및 과적합 방지 비율 설정

5. 실험 및 평가 방법

5.1 베이스라인 모델 설정

본 프로젝트에서는 TF-IDF 방식으로 텍스트를 숫자로 변환한 뒤, 이를 Logistic Regression과 SVM 두 가지 모델에 입력하는 방식을 베이스라인으로 설정한다. 두 모델 모두 비교적 구조가 단순하고 결과 해석이 쉬워, 이후 복잡한 모델과 성능을 비교하는 기준점으로 활용하기에 적합하다. 베이스라인 모델의 성능을 먼저 확인함으로써, 이후 BERT에서 임베딩을 추출해 MLP 분류기에 넣는 방식이 얼마나 더 나은 결과를 내는지 명확하게 비교할 수 있다. 동일한 데이터와 동일한 전처리 과정을 거쳐 실험하므로, 모델 구조 자체에 의한 성능 차이만을 확인할 수 있다.

5.2 실험 설계 방법

전체 데이터는 모델 학습에 사용하는 학습 데이터, 학습 중 성능을 점검하는 검증 데이터, 최종 성능을 측정하는 테스트 데이터로 나누어 활용한다. 비율은 8:1:1 또는 7:1.5:1.5를 기본으로 하며,

10개 사건 유형의 비율이 각 데이터셋에서 비슷하게 유지되도록 나눈다. 모든 모델은 동일한 데이터셋으로 실험하여 공정하게 비교한다. 입력 텍스트는 판시사항만 사용하는 경우, 요약문만 사용하는 경우, 두 텍스트를 합쳐서 사용하는 경우로 나누어 각각 실험을 진행한다.

5.3 모델 성능 평가 지표

모델의 성능을 평가하기 위해 여러 지표를 함께 사용한다. 정확도는 전체 예측 중 맞게 분류한 비율을 나타내며, 가장 기본적인 평가 지표이다. 클래스별 성능 차이를 확인하기 위해 F1-score도 함께 사용한다. F1-score는 정밀도와 재현율을 함께 고려한 지표이다. 10개 사건 유형 각각에 대해 고르게 잘 분류하는지 확인하기 위해 각 유형의 F1-score를 평균 낸 값을 주요 지표로 삼는다. 단순히 숫자 하나로 비교하는 데 그치지 않고, 어떤 사건 유형에서 잘 맞고 어떤 유형에서 틀리는지를 함께 분석하여 객관적인 평가가 이루어지도록 한다.

5.4 모델 비교 및 분석 계획

비교할 모델은 TF-IDF + Logistic Regression, TF-IDF + SVM, BERT에서 임베딩을 추출해 MLP 분류기에 넣는 방식, 그리고 TF-IDF와 BERT 임베딩을 함께 활용하는 하이브리드 방식으로 구성된다. 각 모델은 앞서 설명한 판시사항, 요약문, 두 텍스트 결합인 세 가지에 따라 각각 실험하여, 어떤 조합이 가장 좋은 결과를 내는지 비교한다. 실험 결과는 앞서 정의한 평가 지표를 기준으로 정리하며, 사건 유형별로 어떤 모델이 강점을 보이는지도 함께 분석한다. 최종적으로 이 프로젝트에서 가장 적합한 모델과 입력 방식의 조합이 무엇인지를 근거와 함께 제시하는 것을 목표로 한다.

6. 프로젝트 일정 및 역할 분배

6.1 전체 프로젝트 일정 계획

주차	주요 활동
4~5주차	데이터 수집 및 전처리 (JSON → CSV 변환, 결측치 처리, 텍스트 정제)
6~7주차	EDA 분석 및 Baseline 모델 구축 (TF-IDF + LR/SVM)
8주차	중간발표
9~10주차	BERT 임베딩 추출 및 MLP 분류기 설계
11~12주차	하이브리드 모델 구현 및 전체 실험 수행
13주차	실험 결과 분석 및 성능 비교표 작성
14주차	최종 보고서 제출
15주차	최종 발표

6.2 주요 마일스톤 설정

마일스톤	목표시점	완료기준
데이터셋 구축 완료	5주차	CSV 변환 및 전처리 완료, train/val/test 분할 완료
EDA 분석 완료	7주차	클래스 분포, 텍스트 길이, 카테고리 유사도 분석 완료
중간발표	8주차	Baseline모델 성능 결과 보고
전체 실험 완료	13주차	BERT + MLP, 하이브리드 모델 실험 및 비교표 작성 완료
최종 보고서 제출	14주차	실험 결과 분석 및 보고서 완성
최종 발표	15주차	발표 자료 준비 및 발표 수행

6.3 팀원별 역할 분담

팀원	담당역할	세부내용
이승준	데이터 전처리	JSON → CSV 변환, 결측치 처리, 텍스트 정제, 데이터 분할
이윤수	EDA 및 시각화	클래스 분포, 텍스트 길이 분석, 카테고리 유사도 히트맵
김동현	Baseline 모델	TF-IDF+LR/SVM학습, GridSearchCV 하이퍼파라미터 튜닝
김홍근	Bert + MLP 모델	BERT 임베딩 추출, MLP 설계, 하이브리드 모델 구현
정래원	결과 분석 및 보고서	성능 비교표 작성, Confusion Matrix 분석, 보고서 및 발표 자료

역할 분담은 위 표를 기본으로 하지만, 프로젝트 진행 상황에 따라 유동적으로 조정한다. 각 단계의 산출물은 팀 전체에 공유하며, 단계별 완료 시점에 팀 전원이 결과를 리뷰하여 진행 상황을 함께 점검한다.

7. 기대 효과 및 한계점

7.1 기대 성과 및 활용 가능성

본 프로젝트에서는 법률 판례 텍스트를 대상으로 TF-IDF 기반 표현과 BERT 임베딩 기반 표현의 분류 성능 차이를 비교한다. 판시사항과 요약문 등 입력 텍스트 종류에 따른 성능 변화도 함께 분석하여, 법률 텍스트 분류에 적합한 입력·모델 조합을 제시하고자 한다.

7.2 예상되는 어려움 및 해결 계획

66,511건의 판례에서 BERT 임베딩을 추출하는 데 연산 시간이 많이 걸릴 수 있으므로, Google

Colab GPU 환경에서 배치 단위로 처리한다. 10개 카테고리 간 클래스 불균형에 대해서는 4.3의 class weight 조정 전략으로 대응한다.

7.3 프로젝트의 잠재적 한계

BERT 임베딩을 frozen 상태로 추출하므로 법률 도메인에 최적화된 문맥 표현을 학습하지는 못한다. 입력도 판시사항과 요약문에 한정되어 판결문 전문의 세부 맥락은 반영되지 않는다. 전문을 활용하려면 BERT의 512 토큰 제한을 넘기 위한 별도 입력 처리 기법이 필요하다.

8. 참고문헌

[1] Vatsal, S., Meyers, A., & Ortega, J. E. (2023). Classification of US Supreme Court Cases using BERT-Based Techniques. *arXiv preprint arXiv:2304.08649*.

[2] Lee, J. (2025). Legal text classification in Korean sexual offense cases: from traditional machine learning to large language models with XAI insights. *Artificial Intelligence and Law*. <https://doi.org/10.1007/s10506-025-09454-w>

[3] AI Hub. (2024). 생성형AI 법률/규정 텍스트 분석 데이터 (고도화) - 상황에 따른 판례 데이터. <https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=71723>