

빅데이터프로그래밍 산학협력프로젝트 수행계획서

과제 수행원 현황						
수행 학기	2026학년도 1학기					
프로젝트명	법률 판례 텍스트 기반 사건 대분류 자동 분류 모델 성능 비교					
팀명	레옹					
구분	이름	학번	소속		전화번호	이메일
			1트랙	2트랙		
팀장	정래원	2071117	빅데이터트랙	모바일소프트웨어트랙	010-2205-650	fodnjs15@hansung.ac.kr
팀원	김동현	2371096	모바일소프트웨어트랙	빅데이터트랙	010-6290-1528	0424dhdh@hansung.ac.kr
	김홍근	2191049	웹공학트랙	빅데이터트랙	010-9859-3459	khg9859@gmail.com
	이승준	1971090	빅데이터트랙	웹공학트랙	010-2207-8646	netisky2@hansung.ac.kr
	이윤수	2171120	모바일소프트웨어트랙	빅데이터트랙	010-8277-4058	mooksu2@dau-m.net
지도교수	교과목명		빅데이터프로그래밍		과목코드	V022005
	성명		이청용			
	소속		컴퓨터공학부			
산업체 멘토	기업명		왓차			
	멘토 성명		임해빈	멘토 직위	매니저(ML팀)	

프로젝트 수행계획서	
프로젝트 개요	제목 : 법률 판례 텍스트 기반 사건 대분류 분류 모델 성능 비교 최근 법률 분야에서도 인공지능을 활용한 자동화 연구가 늘고 있다. 판례 문서는 분량이 길고 구조가 복잡해 사건 유형을 파악하고 분류하려면 시간과 전문 지식이 많이 든다. 한편 판례는 계속 쌓이고 있어 사람이 일일이 분류·정리하는 방식만으로는 한계가 있다. 자동으로 사건 유형을 나눌 수 있는 분류 과제의 필요성이 커지는 상황이다. 자연어 처리 기술이 발전하면서 텍스트를 수치화하고 분류하는 방법도 다양해졌고, 특히 사전학습 언어모델은 기존 단어 빈도 중심 방법과 다른 성격의 표현을 제공한다. 본 프로젝트는 AI Hub에서 제공하는 판례 텍스트를 바탕으로 사건 대분류를 예측하는 모델을 설계·실험하고, 표현 방식에 따른 성능 차이를 비교함으로써 법률 텍스트 분류에 대한 실증적 이해를 높이는 것을 목적으로 한다.

	목표는 판례에 실린 텍스트만으로 민사, 가사, 형사, 행정 등 열 개 사건 대분류를 자동으로 예측할 수 있는 모델을 마련하는 것이다. TF-IDF를 쓰는 전통적인 머신러닝 베이스라인과, 사전학습 BERT로부터 얻은 벡터를 입력으로 하는 다층 퍼셉트론 분류기를 구축하여 성능을 대조하고, 법률 문장에서 문맥 정보가 분리에 얼마나 도움이 되는지 함께 살펴본다. 모델을 돌리는 데 그치지 않고 결과를 해석하여 법률 텍스트 분류에 어떤 방식이 유리한지 논의할 수 있는 근거를 만드는 것도 목표에 포함한다. 핵심 질문은 동일한 라벨이 붙은 판례라도 텍스트를 어떻게 표현하느냐에 따라 분류 성능이 어떻게 달라지는가이다. 이를 위해 단어 빈도 중심의 TF-IDF 표현과 문맥을 반영하는 BERT 기반 표현을 같은 데이터와 같은 분할로 비교할 예정이다. 판례에는 판시사항과 요약문처럼 성격이 다른 필드가 있으므로, 어느 쪽이 분류에 유리한지, 두 내용을 이어 붙이면 성능이 좋아지는지도 실험 단계에서 검토한다. 문맥을 활용하는 구성이 베이스라인보다 유리할 수는 있으나 토큰 길이와 클래스 불균형 등 현실 조건에서 항상 그렇지는 않을 수 있어, 결과와 혼동 행렬을 통해 확인한다. 판시사항은 정보가 많고 요약문은 짧으므로 분리 과제에 어떤 입력이 유리한지는 실험 결과로 결론을 내릴 계획이다.
추진 배경	법률 텍스트 분류는 전통적 머신러닝과 사전학습 언어모델 기반 연구로 나누어 볼 수 있다. Vatsal 등은 미국 대법원 판례를 대상으로 Legal-BERT 등 BERT 계열 모델의 분류 성능을 검토하였고, Lee는 한국어 성범죄 판례를 여러 유형으로 분류하며 전통적 머신러닝과 BERT 계열의 차이를 다루었다. AI Hub는 동일 데이터셋을 활용한 판결 예측 등 공식 예시 모델을 제시하나, 본 프로젝트가 다루는 열 개 사건 대분류와 과제 정의는 이와 완전히 같지 않을 수 있어 문제 설정을 문서에 명확히 구분할 예정이다. 선행 연구는 가능성을 보여 주지만 분류 대상이 특정 국가나 특정 죄목 등으로 한정된 경우가 많고, 여러 법 분야를 아우르는 대분류에 초점을 둔 비교는 상대적으로 적다. 입력 필드를 판시사항과 요약문 등으로 나누어 같은 조건에서 성능을 비교한 실험은 흔하지 않으며, TF-IDF 기반 선형 모델과 BERT 임베딩 위의 얇은 분류기를 같은 파이프라인에서 맞추어 보는 형태는 보고서마다 설정이 달라 직접 비교가 어렵다는 점이 있다. 이에 본 팀은 AI Hub 상황별 판례 데이터 약 육만여 건 규모를 출발점으로 삼고, 민사·가사·형사·행정·기업·근로자·특허와 저작권·금융·조세·개인 정보와 ICT 등 열 개 대분류를 목표 변수로 둔다. 같은 데이터에 대해 판시사항 단독, 요약문 단독, 두 텍스트 결합 세 조건으로 입력을 나누어 실험한다. TF-IDF 기반 로지스틱 회귀와 선형 SVM으로 베이스라인을 정한 뒤, 동결된 BERT에서 추출한 벡터를 다층 퍼셉트론에 넣는 구조를 설계하여 단어 빈도 표현과 문맥 표현의 차이를 같은 실험 틀 안에서 본다. 여기에 TF-IDF 특징과 BERT 벡터를 이어 붙인 하이브리드 구성을 추가하여 두 표현을 함께 쓸 때의 효과를 검증한다.
목표 및 내용	모델 설계 열 개 대분류를 맞추기 위해 베이스라인 모델, BERT 임베딩 위의 다층 퍼셉트론, 두 표현을 합친 하이브리드를 순서대로 설계한다. 먼저 TF-IDF로 문서를 벡터화한 뒤 로지스틱 회귀와 선형 SVM을 베이스라인으로 둔다. 다음으로 한국어에 맞는 사전학습 BERT를 불러와 가중치는 고정하고 문장 단위 토큰 시퀀스의 대표 벡터를 추출한 뒤 다층 퍼셉트론으로 열 개 클래스를 맞춘다. 마지막으로 TF-IDF 벡터와 BERT 벡터

를 차원 방향으로 연결한 뒤 동일한 형태의 다층 퍼셉트론으로 분류하는 하이브리드를 구성한다. 하이브리드에서 TF-IDF 차원 수와 BERT 차원 수는 구현 시점에 맞추되 베이스라인과 같은 TF-IDF 설정을 쓰면 비교가 분명해진다.

TF-IDF와 선형 모델은 해석과 비용 측면에서 기준선으로 쓰기에 적합하다. BERT는 문맥 정보를 담은 고정 길이 벡터를 주므로 가중치 전체를 미세조정하지 않고도 단어 빈도만으로는 잡기 어려운 패턴을 보조할 수 있다. 수업에서 허용한 범위와 지도의 지시에 맞추어 동결 추출 후 얇은 분류기만 학습하는 방식을 택한다. 하이브리드는 서로 다른 두 종류의 특징을 동시에 넣었을 때 성능과 안정성이 어떻게 되는지 보기 위한 옵션이다.

데이터 분할 비율은 여덟 대 하나 대 하나 등 팀에서 정한 비율을 적용하고 계층 분할로 라벨 비율을 유지한다. 선형 모델 쪽은 클래스 불균형에 대응하기 위해 소수 클래스에 가중을 주는 설정을 검토한다. BERT 쪽은 사전학습 가중치를 고정하고 추출한 벡터만으로 다층 퍼셉트론을 학습하며 손실 함수는 다중 클래스 분류에 흔히 쓰이는 교차 엔트로피, 최적화는 Adam 등을 사용하는 방향으로 구현한다. 검증 분할로 과적합 여부를 보며 에포크나 학습률은 조정한다.

하이퍼파라미터는 TF-IDF와 선형 모델에 대해 그리드 서치나 유사한 탐색으로 n-그램 범위와 규제 강도 등을 조정할 계획이다. 다층 퍼셉트론에는 은닉층 크기, 드롭아웃, 학습률 등을 바꾸어 가며 검증 성능을 본다. 하이브리드는 입력 차원이 커지므로 과적합 방지 설정을 함께 조정하며 탐색 범위는 계산 시간과 수업 일정 안에서 현실적으로 잡는다.

실험 및 평가 방법

TF-IDF로 만든 특징에 로지스틱 회귀와 SVM을 각각 적용하는 구성을 베이스라인으로 한다. 구조가 단순하고 같은 전처리와 같은 분할 위에서 이후 모델과 숫자를 맞추기 쉬워 비교 축으로 쓴다.

학습, 검증, 테스트를 분리하여 최종 점수는 테스트에 집중하거나 팀 규칙에 따라 검증으로 튜닝만 하고 테스트는 고정한다. 모든 모델은 동일 분할과 동일 입력 조건을 맞춘다. 입력은 앞서 정한 판시사항만, 요약문만, 결합 세 가지로 나누어 반복한다.

정확도에 더해 매크로 F1을 주요 지표로 보고 클래스별 F1과 혼동 행렬로 어느 쌍이 자주 섞이는지 본다. 불균형이 크면 전체 정확도만으로는 오판이 생길 수 있어 매크로 F1을 함께 제시한다.

베이스라인 두 중, BERT 임베딩과 다층 퍼셉트론, 하이브리드를 같은 형태로 정리하고 입력 조건별로 비교한다. 탐색적 분석에서 본 클래스 분포와 텍스트 길이, 혼동 패턴을 연결하여 왜 그런 차이가 났는지 서술한다.

프로젝트 일정 및 역할 분배

먼저 데이터를 받아 필요한 필드만 정리하고 분할까지 마친 뒤, 팀에서 같은 형식으로 쓸 수 있도록 공유한다. 이어서 탐색적 분석과 시각화, 베이스라인 모델을 병행적으로 진행하고, 중간 발표 시점에는 전처리 방향과 베이스라인 결과까지 팀에 공유 가능한 수준을 목표로 한다. 그 다음 단계에서 BERT 임베딩 추출과 다층 퍼셉트론을 구현하고, 이후 하이브리드와 전체 실험을 한데 모아 정리한다. 실험 결과를 비교표 형태로 묶고 해석한 뒤 최종 보고서와 발표 자료로 이어간다. 학과 일정과 중간·기말 시기에 맞추어 세부 일정은 조정할 수 있다.

분석용 데이터셋이 정리되었는지, 탐색적 분석 결과가 남았는지, 베이스라인과 심화

	실험이 끝났는지 등은 단계마다 팀에서 확인한다. 이승준은 JSON에서 필요 필드를 추출하고 정제와 분할, 건수 기록을 맡는다. 이윤수는 클래스 분포와 길이, 유사도 등 탐색적 분석과 시각화를 맡는다. 김동현은 TF-IDF와 로지스틱 회귀·선형 SVM과 하이퍼파라미터 탐색을 맡는다. 김홍근은 동결 임베딩 추출과 다층 퍼셉트론, 특징 결합 실험을 맡는다. 정래원은 성능 비교와 혼동 분석, 보고서와 발표 자료 정리를 맡는다. 역할은 진행에 따라 조정할 수 있으며 단계별 산출물은 공유 후 팀 리뷰로 맞춘다.
기대효과	같은 법률 도메인 데이터에서 표현 방식과 입력 필드 선택이 성능에 미치는 영향을 숫자로 정리할 수 있다. 향후 유사한 분류 과제를 설계할 때 입력 데이터를 무엇을 쓸지 판단하는 참고가 될 수 있다. BERT 벡터 추출은 시간이 들 수 있으므로 GPU 환경에서 배치 단위로 처리하고 중간 결과를 저장해 두고 재실행을 줄인다. 클래스 불균형에는 가중치나 지표 해석으로 대응한다. 일정 대비 연산 부담이 크면 실험 범위를 보고서에 명시한 범위 안에서 조정한다. 한편 BERT 전체를 도메인 데이터로 미세조정하지 않으므로 법률에 특화된 표현을 끝까지 학습한다고 보기는 어렵다. 입력도 판시사항과 요약문 중심이며 판결문 전체는 다루지 않는다. 토큰 길이 상한 때문에 긴 텍스트는 일부만 쓰는 전제가 생긴다.
참고문헌	Vatsal, S., Meyers, A., & Ortega, J. E. Classification of US Supreme Court Cases using BERT-Based Techniques. arXiv:2304.08649. Lee, J. Legal text classification in Korean sexual offense cases: from traditional machine learning to large language models with XAI insights. Artificial Intelligence and Law. AI Hub. 생성형 AI 법률·규정 텍스트 분석 데이터 고도화, 상황에 따른 판례 데이터. https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=71723